

1 Algoritmo Formiga

O primeiro sistema formiga para VRP foi desenhado muito recentemente por **referência**, o qual considera a versão mais elementar do problema: CVRP.

Para mais versões mais complexas de VRP, **referência** tem desenvolvido um sistema de múltiplas colônias de formigas para VRPTW (MACS-VRPTW) o qual é organizado com uma hierarquia de desenho de colônias artificiais de formigas para sucessivamente otimizar uma função de múltiplos objetivos: a primeira colônia minimiza o número de veículos enquanto a segunda colônia minimiza a distância de viagem. Cooperação entre colônias é feita mudando informações através de atualização de feromônio.

Em **referência** desenho, há duas fases básicas de sistemas de formigas: construção de veículos e atualização de trilha, O Algoritmo AS é explicado aqui.

1.1 Algoritmo de Sistema de formigas

Após inicializar o AS, os dois passos básicos de construção de rotas de veículos e atualização de trilha são repetidos para um número de iterações. Considerando a disposição inicial das formigas artificiais foi encontrado que o número de formigas poderia ser igual em cada cliente no início da iteração. O 2-opt-heurística (é explicada explorando todas as permutações obtidas pela mudança de duas cidades) é usado para minimizar a rota de veículos geradas pelas formigas artificiais, consideravelmente melhorar a qualidade da solução. Além disso para esse avançar na pesquisa local também introduzimos uma listade de candidatos para seleção de clientes os quais são determinados na fase de inicialização do algoritmo. Para cada localização d_{ij} ordenamos $V - \{v_i\}$. de acordo com a distância crescente d_{ij} para obter a lista de candidatos. A proposição de AS para CVRP pode ser descrita pelo seguinte algoritmo esquemático:

1. Inicialize
2. Para I^{\max} iterações faça:
 - (a) Para todas as formigas gerar um nova solução usando a Fórmula 1 e a lista de candidatos
 - (b) Melhorar todas as rotas de veículos usando o 2-opt-heurística
 - (c) Atualizar as trilhas de feromônio usando Fórmula 2.

1.2 Construção da rota de veículos

Para resolver o VRP, as formigas artificiais constroem soluções escolhendo cidades sucessivas para visitas, até que cada cidade tenha sido visitada. Sempre que a escolha de outra cidade poder levar a uma solução impossível para resolver do veículo capacitado ou de comprimento total, o depósito é escolhido e uma nova rota é iniciada. Para a seleção de uma cidade, dois aspectos são levados em conta: qual boa foi a escolha desta cidade, um informação que é guardada nas trilhas de feromônio τ_{ij} é associada com cada arco (v_i, v_j) , e como prometido é a escolha desta cidade. Essa última medida de desidade, chamada visibilidade e denotada por n_{ij} , é a função de heurística local mencionada acima.

Com $\Omega = \{v_i \in V : v_j \text{ é possível ser visitado}\} \cup \{v_0\}$, a cidade v_j é selecionada para ser visitada com segue:

$$p_{ij} = \begin{cases} \frac{[\tau_{ij}]^\alpha [\eta_{ij}]^\beta}{\sum_{k \in \Omega} [\tau_{ik}]^\alpha [\eta_{ik}]^\beta} & \text{if } v_j \in \Omega \\ 0 & \text{caso contrário} \end{cases}$$

Essa possibilidade de distribuição é inclinada pelos parâmetros α e β que determinam a influência relativa das trilhas e a vizibilidade, respectivamente. A vizibilidade é determinada como a recíproca da distância, e a probabilidade de seleção é então estendida pela informação específica do problema. Aqui, a inclusão de poupaças e capacidade utilizam a liderança para melhorar resultados. De outra forma, o último é relativamente custoso em termos de tempo computacional e assim não usaremos neste paper. Assim, introduziremos os parâmetros f e g , e usaremos os seguintes função paramétrica de economia para a visibilidade:

$$\eta_{ij} = d_{i0} + d_{0j} - g d_{ij} + f |d_{i0} - d_{0j}|$$

1.3 Atualização de trilha

Após uma formiga artificial ter construído uma solução possível, as trilhas de feromônio são sulcadas(?) dependendo do valor objetivo da solução. Essa regra de atualização é como segue:

$$\tau_{ij}^{new} = p \tau_{ij}^{old} + \sum_{\mu=1}^{\sigma-1} \Delta \tau_{ij}^{\mu} + \sigma \Delta \tau_{ij}^*$$

onde p é a persistência da trilha (com $0 \leq p \leq 1$, assim a evaporação da trilha é dada por $(1-p)$). Únicamente se o arco (v_i, v_j) foi usado pela μ -ésima melhor formiga, a trilha de feromônio é incrementada em $\Delta \tau_{ij}^{\mu}$ o qual é então igual a $(\sigma - \mu)/L_{\mu}$, e 0 caso contrário. Além disso para que, todos os arcos pertençam a melhor solução é enfatizado com se σ formiga elitista fossem usadas então. Assim, cada formiga elitista incrementa a intensidade da trilha em $\Delta \tau_{ij}^*$ que é igual a $1/L^*$ se o arco (v_i, v_j) pertence a melhor solução, e 0 caso contrário.

2 Algoritmo de programação de restrições

A programação de restrições (CP) [referência](#) é um paradigma para representar e resolver uma larga variedade de problemas. Problemas são expressos em termos de variáveis, domínios para estas variáveis e restrições entre as variáveis. Os problemas são então resolvidos usando técnicas de pesquisa completa tais como depth-first search e branch e bound. A riqueza de linguagem usada para expressar problemas em CP faz este um candidato ideal para VRPs. Isso possibilita a utilização de expressões mais gerais. Além disso expressões envolvendo a aritmética usual e operações lógicas, restrições simbólicas complexas podem ser usadas para descrever problemas. CP melhora a pesquisa usando propagação de restrições. Se os limites ou restrições de uma variável podem ser inferidos, ou são conjuntos testáveis, essas mudanças são "propagadas" através de todas as restrições para reduzir o domínio de variáveis restritoras.

Em cada nó na árvore de pesquisa, os mecanismos de propagação removem valores do domínio de variáveis restritoras que são inconsistentes com outras variáveis. Se o mecanismo de propagação remove todos os valores de uma variável, então não pode haver uma solução nesta sub-árvore e a pesquisa de rastros faz uma decisão diferente no ponto de rastro. Rastreio é cronológico: decisões podem somente ser desfeitas em ordem oposta a qual elas foram feitas. Contudo, os domínios das variáveis de restrição podem somente ser reduzidos com uma pesquisa descendente na árvore. O domínio de todas as variáveis de restrição pode ser restaurado pelo rastro para um nó anterior, mas geralmente o aumento de domínios não é suportado. Isso tem implicações importantes para os meios nos quais o VRP é resolvido.

No caso particular de resolver VRP, uma variável de decisão R_i é associada com cada cliente visitado i , representando a próxima visita feita pelo mesmo veículo. Para cada veículo k , há visitas adicionais S_k fazendo o início da rota, e E_k fazendo o fim da rota. Para ler o fim do itinerário para um veículo k , iniciado em S_K e seguindo o próximo ponteiro através de E_k .

O conjunto de clientes visitados será referenciado com N , a visita inicial com S , e a visita final com E . $A =_{def} N \cup S \cup E$ são todas as visitas. Observando R como uma função, R aplica $N \cup S$ sobre $N \cup E$.

Modelar VRP é desejável ter um tipo de restrição especial para distribuir restrições ao longo dos caminhos. As restrições são da forma $R_i = j \Rightarrow Q_j \geq Q_i + q_{ij}$.

Assim, se o visitante j segue imediatamente o visitante i , a quantidade Q é acumulada. Por exemplo, tomando-se q_{ij} igual a o tempo de viagem entre i e j isto seria a o tempo de chegada em j . Tomando-se q_{ij} como a demanda em i que seria acumulada no veículo. Isso significa permitir outra restrição do mundo real ser expressa sucintamente.

Em cada caso um ponto fixo deve ser suprimido, por exemplo $Q_i = 0 \forall i \in S$ no caso de restrições de carga. Uma simples restrição deste tipo a qual restringe a limite superior também deve ter os efeitos de eliminação de subrotas.

2.1 Restrições para VRP

2.2 Núcleo de restrições

- Time: é restrito pelo dia de trabalho e pelo tempo de entrega do cliente.
- Capacity: pode ser restrito em termos de peso, volume, número de lugares de pallet, etc.

Uma restrição de caminho pode ser usada para propagar o tempo inicial do serviço de um cliente ao longo de cada rota de veículos. Neste caso, q_{ij} é o tempo de serviço em i , mais o tempo de viagem para j .

Um serviço de tempo de janela simples ou múltiplo poderia ser tomado restringindo fortemente o início da variável de serviço para cada visita. O início e o fim de cada dia de trabalho para cada veículo pode ser representada impondo a janela de tempo em S e E .

Um método de modelamento das restrições de capacidade em um veículo é propagar os espaços livres no veículo ao longo da rota do veículo. O modelo F_i como o espaço livre na chegada de um visitante i , q_{ij} é a mudança no espaço livre associado com o visitante i . Para indicar que todos os veículos devem ser sobrecarregados em

algum tempo, restrições da forma $F_i \geq 0 \forall i \in A$ são impostas. Para o veículo k com capacidade c_k , o ponto fixo $F_k = c_k$ para $k \in S$ pode ser tomado. Simultâneas recepções e entregas podem ser modeladas num modo similar, mais isso não é discutido aqui.

2.3 Restrições de Tamanho

Um dos benefícios da técnica CP é que as restrições de tamanho pode ser incorporadas sobre o modelo com facilidade comparativa. Por exemplo, algumas visitas pode requerer equipamentos especiais, ou alguns veículos pode ser simplesmente muito grandes para entrar nas premissas. Assim, precisamos ser capazes de não permitir uma visita sendo feita por um veículo particular.

Modelamos isso por uma etiqueta de veículo τ_k para cada visitante k de cada rota, usando uma restrição similar para a restrição de caminho para a qual $R_i = j \rightarrow \tau_j = \tau_i$ com $\tau_i = i$ para $i \in S$. Assim visitas de clientes servidos pelo veículo k tem etiqueta k . O veículo k é então esquecido pela visita i feita impondo-se uma restrição da forma $\tau_i \neq k$. Um conjunção de tal expressão pode ser usada para excluir mais que um veículo.

O requerimento que duas visitas i e j devem ser feitas pelo mesmo veículo pode também ser especificada usando a etiqueta: $\tau_i = (\neq)\tau_j$.

Melhorando um tamanho de capacidade para um veículo prove um exemplo final que demonstra um poderoso uso das etiquetas de veículos. Uma restrição de comprimento é diferente de uma restrição de capacidade já que esta não se acumular sobre uma rota. Se o visitante i envolve bens de comprimento l , e L_k é o comprimento do veículo k , então a restrição $L(\tau_i) \geq l$ defini-se a restrição de comprimento.

2.4 Estratégia de pesquisa

Soluções o problema CP são usualmente encontradas usando-se métodos completos tais como pesquisa de primeira-profundidade e branch e bound. Contudo, para o problema de roteamento de tamanhos práticos, métodos de pesquisa completa não podem produzir soluções em tempo curto e em periodos de tempo realizaveis. Em constraste, métodos de melhoramento iterativo tem provado muito sucesso nesta perspectiva. Métodos de melhoramento iterativo tem operam por mudar pequenas partes da solução, por exemplo movendo um vizitante de uma rota para outra. Esse tipo de operação envolve decisões de retração previas e fazer novas. Em contraste a pesquisa de primeira-profundidade, as restrições podem ser feitas em alguma ordem, não simplismente na ordem oposta em que a decisão foi tomada. Em geral a essencia deste tipo de implementação de mecanismo de retração não-cronológica em CP trabalha em alto nível.

Para superar este problema, o sistema CP é unicamente usado para checar a validade das soluções e determinar o valor das variáveis de restrição, não para pesquisar soluções. A pesquisa é feita por um processo iterativo de melhoramento. Quando o processo precisa checar a validade de uma solução potencial, é tomado o sistema CP. Como parte da checagem, a propagação de restrições usando todas as restrições sobre o lugar. Isso agrega valor à checagem de restrições, como o método iterativo de melhoria pode então tomar a vantagem do domínio reduzido para elevar a

velocidade da pesquisa por melhorar a legalidade da checagem rápida.

A melhoria depende de duas representações da solução. Há uma representação passiva, a qual é o modelo contra o qual as novas soluções são construídas, e para o qual a (não necessariamente a melhor solução). A segunda é uma representação ativa que mantém as variáveis de restrição, e dentro das quais a propagação de restrições toma lugar. Variáveis de estado na representação ativa são (o domínio atual é salvo) antes que alguma mudança seja feita, então este domínio pode ser restaurado depois.

Quando o sistema CP propagação e checam de validade instantaneamente o conjunto das variáveis de decisão R usando a iteratividade da representação passiva. As restrições então propagam as variáveis de restrição (tais como tempo e variáveis de capacidade) tem seu domínio reduzido. Se alguma variável tem um valor ilegal, a solução é ilegal.

3 Recozimento Determinístico

Recozimento determinístico opera num modo que é semelhante a SA, exceto que uma regra determinística é usada para a aceitação do movimento. Duas implementações padrão desta técnica são limiar aceito [referenciar](#) e registro para registro de viagem [referencia](#).

Ná iteração t de um algoritmo de limiar aceito, a solução x_{i+1} é aceita se $f(x_{i+1}) \leq f(x_i) + \theta_1$, onde θ_1 é um parametro de controle usual. Na viagem de registro-a-registro um registro é a melhor solução x_* encontrada durante a pesquisa. Na iteração t , a solução x_{i+1} é aceita se $f(x_{i+1}) \leq \theta_2 f(x_i)$, onde θ_2 é um parametro de controle usado fracamente maior que 1.

4 Algoritmo Genético

Algoritmos genéticos são muito provavelmente as mais largamente conhecidas metehuristics, hoje aceitando atenção comentável sobre todo o mundo. Algoritmos genéticos são processos computacionais que empregam os mecanismos naturais de seleção e genética natural para envolver soluções para problemas. O conceito básico foi desenvolvido por [referenciar](#), enquanto a praticidade do uso de GA para resolver problemas complexos foi demonstrada em [referenciar](#) e [referenciar](#). GA envolve uma população de indivíduos codificados com cromossomos criando-se uma nova geração de prole por meio de um processo iterativo até algum critério de convergência ser encontrado. Tal critério poderia, por exemplo, [referenciar](#) o número máximo de gerações, a convergência para uma população homogênea composta por indivíduos similares, ou dando uma solução ótima. O melhor cromossomo gerado é então decodificado, provendo a solução correspondente.

Algoritmos genéticos trabalham com uma população de candidatos a solução em vez de apenas uma simples solução, então ela faz um modo de pesquisa simultânea. Cada indivíduo representa uma população de soluções potenciais para o problema. No GA original de Holland cada solução podia ser representada como uma string de bits, onde a interpretação do significado da string especifica o problema.

O critério de uma nova geração de indivíduos envolve três grandes passos ou fases:

- A fase de seleção consiste de uma escolha randômica de dois indivíduos parentes da população para propositos de acasalamento. A probabilidade da selecionar um membro de uma população é geramente proporcional a sua aptidão para enfatizar a qualidade genética enquanto a manutenção da diversidade genética. Aqui, aptidão referece a uma medida de lucro, utilidade ou bondade a ser máximizada enquanto explora o espaço de solução.
- O processo de recombinação ou reprodução faz uso da seleção de genes de parentes selecionados para produzir prole que formará a próxima geração.
- A mutação consiste de modificações randômicas de alguns genes de um indivíduo simples num tempo para fortalecer o espaço de soluções a explorar e assegurar, ou preservar, a diversidade genética. A ocorrência de mutações é associado geralmente com uma pequena probabilidade.

Um nova geração é criada para repetir a seleção, processos de reprodução e mutação até todos os cromossomos na nova população substituir aqueles os antigos. Um balanço próprio entre a qualidade genética e a diversidade é assim necessário dentro de uma população ordem para suportar pesquisas eficientes. Na figura abaixo podemos ve o pseudocodigo de um simples GA.

Algorithm 1 Pseudocode for a Genetic Algorithm

```

1:  $t \leftarrow 0$ ;
2: InitPopulation[ $P(t)$ ]; {Initializes the population}
3: EvalPopulation[ $P(t)$ ]; {Evaluates the population}
4: while not termination do
5:    $P'(t) \leftarrow \text{Variation}[P(t)]$ ; {Creation of new solutions}
6:   EvalPopulation[ $P'(t)$ ]; {Evaluates the new solutions}
7:    $P(t+1) \leftarrow \text{ApplyGeneticOperators}[P'(t) \cup Q]$ ; {Next generation pop.}
8:    $t \leftarrow t+1$ ;
9: end while

```

Para resolver o VRP com GAs, é usual representar cada indivíduo por apenas um cromossomo, o qual é uma cadeia de inteiros, cada um deles representando um cliente ou um veículo. Então cada identificador de veículo representa no cromossomo um separador entre duas rotas, e uma string de identificadores de strings, representa a sequência das entregas que um veículo deve cobrir dutante sua rota. Na figura abaixo podemos ver uma representação de uma possível solução pra VRP com 10 clientes e 4 veículos. Cada rota inicia e termina no depósito. Se encontramos na solução dois identificadores de veículos não separados por algum idenfificador de cliente, entedenmos que a rota é vazia, assim, não será necessário usar todos os veículos disponíveis.

$$\underbrace{4-5-2}_{\text{route1}}-11-\underbrace{10-3-1}_{\text{route2}}-13-\underbrace{7-8-9}_{\text{route3}}-12-\underbrace{6}_{\text{route4}}$$

Uma típica função de aptidão usada para resolver o VRP com GA é $f_{eval}(x) = f_{\max} - f(x)$, onde $f(x) = total_{distancia}(x) + \lambda sobre_{carga}(x) + \mu sobre_{tempo}(x)$

Tanto a função de sobre carga quanto a função de sobre tempo retornam o quanto de capacidade e sobre tempo o pode ser permitido. Se nenhuma das restrição da

função são violadas, f retorna a distância total da viagem. Em outros casos tanto capacidade e tempo são pesados com valores λ e μ . A melhor solução pode ter valores fechados para f_{\max} , enquanto a solução que quebra em alguma restrição será penalizada seu valor de aptidão.

5 Cozimento Simulado

O cozimento simulado (SA) é uma técnica de relaxamento simulado, o qual tem sua origem na mecânica estatística. É baseada numa analogia do processo de cozimento de sólidos, onde um sólido é esquentado à uma temperatura alta e gradualmente esfriado de modo a cristalizar numa configuração de baixa energia. SA pode ser visto como um meio de tentar para permitir uma dinâmica básica de escalada na colina para também ser a escape ótimo global de soluções de qualidade pobre. SA guia o pesquisa local original se $\Delta \leq 0$, onde $\Delta = f(x) - f(x_i)$. Permitir a pesquisa escapar um ótimo local, mover este crescimento os valores da função objetivo são aceitas com uma probabilidade $e^{-\Delta/T}$ se $\Delta > 0$, onde T é um parâmetro chamado de "temperatura". O valor de T varia de um valor relativamente grande para um valor pequeno próximo de zero. Esses valores são controlados por plano frio, o qual especifica o início, o valor de temperatura em cada estante do algoritmo.

Na iteração t de um cozimento simulado, a solução é desenhada randomicamente em $N(x_i)$. Se $f(x) \leq f(x_i)$, então x_{i+1} é tomado igual a x ; caso contrário

$$x_{i+1} = \begin{cases} x & \text{with probability } p_i \\ x_i & \text{with probability } 1 - p_i \end{cases},$$

onde p_i é usualmente uma função decrescente de t e de $f(x) - f(x_i)$. É comum definir p_i como $e^{-\Delta/T}$.

Há três critérios comuns de parada:

1. O valor f^* da incumbência x^* não tem decrescimento de no mínimo $\pi_1\%$ para no mínimo k_1 ciclos consecutivos de T iterações;
2. O número de movimentos aceitos tem sido menor que $\pi_2\%$ de T para k_2 ciclos consecutivos de T iterações;
3. k_3 de T iterações tem sido executadas.

6 Pesquisa Tabular

O conceito básico de pesquisa tabular (TS) como descrito por [referência](#) é uma meta-heurística enraizada por outras heurísticas. TS explora o espaço de solução movendo em cada iteração de uma solução s para a melhor solução num subconjunto das suas vizinhanças $N(s)$. Contrariando aos métodos clássicos descendentes, a solução atual pode ser determinada de uma iteração para a próxima. Assim, para ciclos vazios, as soluções possuem alguns atributos de soluções exploradas recentemente que são declarados temporariamente secretos ou esquecidos. A duração que estes atributos permanecem secretos é chamado sua tabu-tenure e pode variar sobre diferentes intervalos de tempo. O estado de segredo pode overridden se certas condições são

encontradas; isso é chamado o critério de aspiração e acontece, por exemplo, quando a solução secreta é melhor que alguma solução vista previamente.

A tendência de resolução apresentada de uma carta de curso, pode ser lamentável como uma fonte de erro mais pode também prover uma fonte de ganho. O método de segredo opera neste modo como a exceção que cursos novos não são escolhidos randomicamente. Em vez de processos de pesquisa secreta acordada pela suposição que não há pontos em acerto (?) uma nova solução a menos que seja um caminho vazio já investigado. Isso garante novas regiões de um espaço de solução de problemas será investigada com uma meta de evitar o mínimo local e ultimamente encontrar a solução desejada.

A solução inicial é tipicamente criada com alguns heurísticas de inserção baratas. Após criada uma solução inicial, um trabalho dado é feito para melhorar usando pesquisa local com um ou mais estruturas de vizinhanças e uma estratégia de aceitação melhor. Muitas das vizinhanças usadas são conhecidas e foram previamente introduzidas no contexto de várias construções e heurísticas de melhorias.

Aqui, descreveremos três algoritmos diferentes para TS:

- Segredo granular
- O processo de memória adaptativa
- Kelly e Xu

6.1 Segredo granular

A pesquisa secreta granular (GTS) é um conceito de promessa muito aceita. Foi recentemente introduzida por [referencia](#) e tem produzido resultados excelentes no VRP. A ideia essencial por trás do tronco do GTS vem da observação que as arestas longes de um grafo somente tem uma probabilidade pequena de pertencem a uma solução ótima. Assim, eliminação de todos os ramos